# Научная и компьютерная коммуникация в современных условиях

«Обнаружение разладки с помощью метода SSA»

Кононыхин Иван Александрович

группа 20.М03-мм Санкт-Петербургский государственный университет Прикладная математика и информатика

2022

Введение в теорию

#### Основные обозначения

#### Обозначения

```
F^{(1)} = F_{N_1}^{(1)}, \ F^{(2)} = F_{N_2}^{(2)} - временные ряды. 
 L: 2 \leq L \leq \min(N_1-1,N_2) - длина окна. 
 U_l^{(1)}, \ l=1,\ldots,L- собственные векторы траекторной матрицы ряда F^{(1)} 
 \mathfrak{L}^{(L,1)} — линейное пространство, натянутое на L—сдвинутые векторы ряда F^{(1)}, \ d \stackrel{\text{def}}{=} \dim \mathfrak{L}^{(L,1)} 
 I = \{i_1,\ldots,i_r\} — подмножество \{1,\ldots,L\} 
 \mathfrak{L}_r^{(1)} \stackrel{\text{def}}{=} \operatorname{span}(U_l^{(1)}, \ l \in I) 
 X_1^{(2)},\ldots,X_{K_2}^{(2)}-L-сдвинутые векторы ряда F^{(2)}
```

## Индекс неоднородности

### Определение

Индекс неоднородности:

$$g(F^{(1)}; F^{(2)}) = \frac{\sum_{l=1}^{K_2} \operatorname{dist}^2(X_l^{(2)}, \mathfrak{L}_r^{(1)})}{\sum_{l=1}^{K_2} \|X_l^{(2)}\|^2} = \frac{\sum_{l=1}^{K_2} (\|X_l^{(2)}\|^2 - \sum_{i=1}^r \langle X_l^{(2)}, U_i^{(1)} \rangle^2)}{\sum_{l=1}^{K_2} \|X_l^{(2)}\|^2} = 1 - \frac{\sum_{l=1}^{K_2} \sum_{i=1}^r \langle X_l^{(2)}, U_i^{(1)} \rangle^2}{\sum_{l=1}^{K_2} \|X_l^{(2)}\|^2}.$$

Индекс неоднородности характеризует несоответствие между рядом  $F^{(2)}$  и структурой ряда  $F^{(1)}$  (описываемого подпространством  $\mathfrak{L}_r^{(1)}$ ).  $g \in [0,1]$ .

## Обозначения

```
F_N:F_N=(f_0,\ldots,f_{N-1}),\,N>2 — исходный временной ряд; F_{i,j} — подряды ряда F_N:F_{i,j}=(f_i,\ldots,f_j),\,\,0\leq i< j\leq N-1; B — длина базовых подрядов ряда F_N:B>L; T — длина тестовых подрядов ряда F_N:T\geq L; F_{i,i+B-1} — Базовый подряд. F_{i,i+T-1} — Тестовый подряд.
```

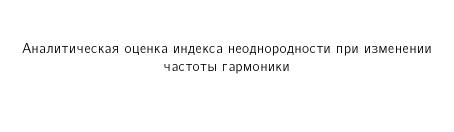
# Строковая функция обнаружения неоднородности

#### Определение

Ряд  $D_{T,N}^{(r)}$ , элементы которого задаются как

$$d_{n-1}^{(r)} \stackrel{\text{def}}{=} g(F_{1,B}; F_{n-T+1,n}), T \leq n \leq N.$$

есть строковая функция обнаружения.



## Постановка задачи

### Задача

Попробуем аналитически упростить индекс неоднородности g, чтобы явно увидеть, как разности частот ряда до и после разладки влияют на его значения.

Рассмотрим ряд

$$F_N = \begin{cases} C_1 \sin(2\pi\omega_1 n + \phi_1), & n \in [0, Q - 1], \\ C_2 \sin(2\pi\omega_2 n + \phi_2), & n \in [Q, N - 1]. \end{cases}$$

Пусть  $\omega_1 \neq \omega_2$ ;  $C_1 = C_2$ . Для простоты зададим амплитуды  $C_1 = C_2 = 1$ .

## Индекс неоднородности

$$\begin{split} g(F^{(1)};F^{(2)}) &= \frac{\sum\limits_{l=1}^{K_2} \operatorname{dist}^2(X_l^{(2)},\mathfrak{L}_r^{(1)})}{\sum\limits_{l=1}^{K_2} \|X_l^{(2)}\|^2} = \frac{\sum\limits_{l=1}^{K_2} (\|X_l^{(2)}\|^2 - \sum\limits_{i=1}^r \langle X_l^{(2)},U_i^{(1)}\rangle^2)}{\sum\limits_{l=1}^{K_2} \|X_l^{(2)}\|^2} = \\ &= 1 - \frac{\sum\limits_{l=1}^{K_2} \sum\limits_{i=1}^r \langle X_l^{(2)},U_i^{(1)}\rangle^2}{\sum\limits_{l=1}^{K_2} \|X_l^{(2)}\|^2}. \end{split}$$

## Индекс неоднородности: аппроксимация

$$\begin{split} g(F^{(1)};F^{(2)}) &= 1 - \frac{\sum\limits_{l=0}^{K_2-1}\sum\limits_{i=0}^{r-1}\langle X_l^{(2)},U_i^{(1)}\rangle^2}{\sum\limits_{l=0}^{K_2-1}\|X_l^{(2)}\|^2} \approx \\ &\approx 1 - \frac{\frac{K_2\cdot 2}{L}\cdot\left[\left(\frac{\sin(2\pi Lb)}{4\pi b} - \frac{\sin(2\pi La)}{4\pi a}\right)^2 + \left(\frac{\cos(2\pi Lb)-1}{4\pi b} - \frac{\cos(2\pi La)-1}{4\pi a}\right)^2\right]}{K_2\cdot\frac{L}{2}} = \\ &1 - \frac{\left[\left(\frac{\sin(2\pi Lb)}{4\pi b} - \frac{\sin(2\pi La)}{4\pi a}\right)^2 + \left(\frac{\cos(2\pi Lb)-1}{4\pi b} - \frac{\cos(2\pi La)-1}{4\pi a}\right)^2\right]}{\frac{L^2}{4}} = g_a(\omega_1,\omega_2), \end{split}$$

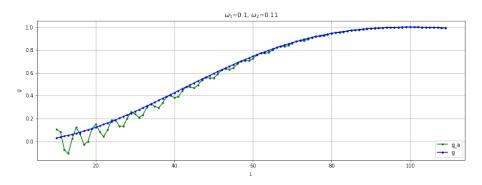
где  $a = \omega_1 + \omega_2$ ,  $b = \omega_1 - \omega_2$ .

# Проверка точности аппроксимации: изменения L

Зададим параметры:

N = 700, Q = 301, B = 200, T = 200

Зафиксируем частоты и будем изменять L.



Система обнаружения структурной неоднородности ряда с автоматически выстраиваемым порогом срабатывания на основе выведенной аналитической формулы.

## Постановка задачи

### Рассмотрим ряд

$$F_{N} = \begin{cases} C \sin(2\pi\omega_{1}n + \phi_{1}), & n \in [0, Q - 1], \\ C \sin(2\pi\omega_{2}n + \phi_{2}), & n \in [Q, N - 1], \end{cases}$$

где Q — момент возмущения.

#### Система:

- Вход:
  - $\bullet$   $F_N$ ;
  - ② k длина интервала, за который нужно определить момент возмущения  $\hat{Q}$ .
- Выход:
  - $oldsymbol{0}$   $\hat{Q}$  момент обнаружения неоднородности.

#### Задача:

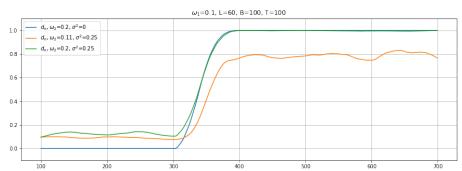
Выбрать порог  $\gamma$  так, чтобы  $\hat{Q} \in [Q, Q+k]$ .

## Oценка $\gamma$

В качестве верхней границы можно взять значение  $\gamma=1$ , однако в таком случае  $\hat{Q}$  будет либо больше Q+k, либо, при  $\omega_1\approx\omega_2$  функция  $d_n$  никогда не достигнет 1.

При добавлении шума с дисперсией  $\sigma^2$  строковая функция неоднородности  $d_n$  до разладки смещается от 0. Если взять слишком маленькое значение  $\gamma$ ,  $\hat{Q} < Q$ .

Для таких рядов надо либо знать  $\sigma^2$ , либо иметь данные для оценки значений  $d_n$  где точно отсутствует неоднородность.

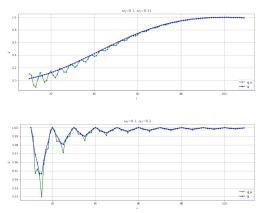


## Оценка $\gamma$ : нижняя граница

Предположим, у нас есть нужные данные и мы смогли оценить нижнюю границу  $\gamma = \gamma_{min}$ .

## Оценка $\gamma$ : верхняя граница

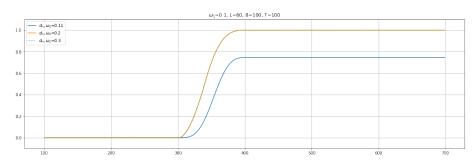
Для определения верхней границы  $\gamma = \gamma_{max}$  мы можем воспользоваться аналитической аппроксимацией  $g_a$ . При достаточно больших L  $g_a \approx g$ .



Однако, для того, чтобы использовать  $g_a(\omega_1,\omega_2)$ , нам нужно знать частоты до и после разладки.

## Предпосылки: влияние изменения частот.

По свойству индекса неоднородности, чем больше  $|\omega_2-\omega_1|$ , тем ближе g к 1 после переходного интервала.



## Оценка $\gamma$ : верхняя граница

Добавим еще 2 параметра, подаваемых на вход системе:

- $\omega_1$  начальная частота ряда;
- $\omega_{min} = \omega_1 + \Delta_{min}$ , где  $\Delta_{min}$  минимальное для обнаружения неоднородности отклонение частоты ряда от  $\omega_1$ ;

Таким образом, можем взять  $\gamma_{max}=g(\omega_1,\omega_{min}).$ 

Так как мы не значем значения  $\omega_2$ , а  $\omega_{min}$  — входной параметр, мы не можем положить  $\gamma=\gamma_{max}$  по тем же причинам, почему и  $\gamma_{max}=1$ . Однако при наличии аппроксимации  $a_T$  переходного интервала кривой  $d_n$ , мы можем взять  $\gamma$  как значение  $a_T$  в точке k.

# Предпосылки: переходный интервал

Матрица  $\mathbb{X}$  имеет размерность  $L \times K$ . Рассмотрим траекторные матрицы  $\mathbb{X}_{test}^{(j)}$  размерности  $L \times K_{test}$  тестовых рядов  $F_{j,j+T}$ , где  $K_{test} = T - L + 1$ ,  $j \in [0, N - T)$ .  $\forall j \in [0, Q - T), \forall n \in [1, K_{test}] : X_n \in \mathbb{X}_{test}^{(j)}, X_n \in \mathfrak{L}_r^{(1)}$ .  $\forall j \in [Q + T, N - T), \forall n \in [1, K_{test}] : X_n \in \mathbb{X}_{test}, X_n \notin \mathfrak{L}_r^{(1)}$ .

При  $T>2\cdot L$ ,  $\forall\,j\in[Q-T+L,Q-L)$ ,  $X_{test}^{(j)}$  состоит из:

- $n_B = n_B(j)$  векторов вложений, лежащих в  $\mathfrak{L}_r^{(1)}$ ;
- $n_T = n_T(j)$  векторов вложений, содержащих момент возмущения;
- $n_H = n_H(j)$  векторов вложений, содержащих только значения ряда после разладки.

Причем  $K_{test} = n_B + n_T + n_H$ 

## Предпосылки: переходный интервал

Пусть L — фиксировано.

$$1 - \frac{\sum\limits_{l=1}^{K_{test}} \sum\limits_{i=1}^{r} \langle X_{l}, U_{i}^{(1)} \rangle^{2}}{\sum\limits_{l=1}^{K_{test}} \|X_{l}\|^{2}} =$$

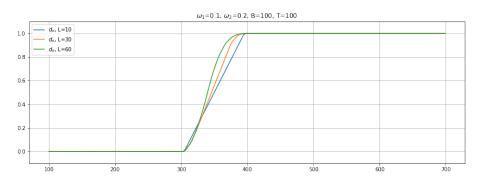
$$=1-\frac{\sum\limits_{l=1}^{n_{B}}\sum\limits_{i=1}^{r}\langle X_{l},U_{i}^{(1)}\rangle^{2}+\sum\limits_{l=n_{B}}^{n_{B}+n_{T}}\sum\limits_{i=1}^{r}\langle X_{l},U_{i}^{(1)}\rangle^{2}+\sum\limits_{l=n_{B}+n_{T}}^{K_{test}}\sum\limits_{i=1}^{r}\langle X_{l},U_{i}^{(1)}\rangle^{2}}{\sum\limits_{l=1}^{n_{B}}\|X_{l}\|^{2}+\sum\limits_{l=n_{B}}^{n_{B}+n_{T}}\|X_{l}\|^{2}+\sum\limits_{l=n_{B}+n_{T}}^{K_{test}}\|X_{l}\|^{2}}=$$

$$=1-\frac{0+\sum\limits_{l=n_{B}}^{n_{B}+n_{T}}\sum\limits_{i=1}^{r}\langle X_{l},U_{i}^{(1)}\rangle^{2}+n_{H}(j)\cdot c_{H}}{c_{1}+\sum\limits_{l=n_{B}}^{n_{B}+n_{T}}\|X_{l}\|^{2}+c_{2}}\approx1-\frac{n_{H}(j)\cdot c_{H}}{c_{1}+c_{2}}.$$

При  $j \in [Q - T + L, Q]$ ,  $n_H(j) = j - Q + T - L$ . Отсюда, при  $T \to \infty$ ,  $n_H \to \infty$  и переходный интервал  $d_n$  более линеен.

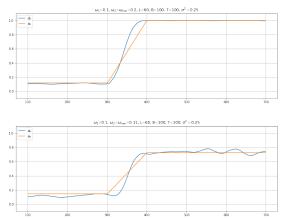
# Предпосылки: переходный интервал

Аналогично, увеличивается  $n_T(j)$  и при уменьшении L.



# Аппроксимация: Идея

Таким образом, мы можем аппроксимировать переходный интервал от  $\gamma_{min}$  до  $\gamma_{max}$  прямой  $a_T$ .



Важно отметить, раз мы хотим брать  $\gamma$  как значение  $a_T$  в точке k, нам важно чтобы начало прямой  $a_T$  было не больше, чем значения  $d_n$  на переходном интервале. Однако такая аппроксимация не всегда корректна.

# Определение $\hat{Q}$

Таким образом, выбрав  $\gamma = \gamma_a$  — значение линейной аппроксимации  $a_T$  переходного интервала функции  $d_n$  в точке k, будем сигнализировать об обнаружении неизвестного момента возмущения Q как момент  $\hat{Q}$  преодоления  $\gamma_a$ .

# Алгоритм работы

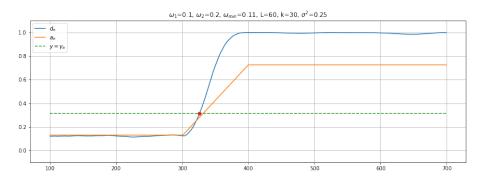
#### Формализуем систему:

- Входные данные:  $F_N$ ,  $\omega_1$ ,  $\omega_{min}$ , k;
- Результат: Q̂;
- Алгоритм:
  - lacktriangle Вычисление  $oldsymbol{\gamma}_{min}$ ,  $oldsymbol{\gamma}_{max}$ ;
  - **2** Аппроксимация переходного интервала  $a_T$ ;
  - $\bigcirc$  Фиксирование  $\gamma_a$ ;
  - ullet Определение  $\hat{Q}$  как момент преодоления  $d_n$  значения  $\gamma_a$ .

## Пример работы

Зафиксируем параметры:  $\omega_1=\frac{1}{10}$ ,  $\omega_{min}=\frac{1}{100}$ , k=30,  $\omega_2=\frac{1}{5}$ , Q=301, L=60, B=100, T=100,  $\sigma^2=0.25$ .

При таких параметрах, для графика ниже  $\gamma_{min}=0.13, \gamma_{max}=0.725,$   $\gamma_a=0.311,~\hat{Q}=326.$ 



## Параметры

Все параметры, используемые выше можно разделить на категории:

- **1** Входные:  $\omega_1$ ,  $\omega_{min}$ , k;
- ② Зависимые от входных параметров:  $\gamma_{min}$ ,  $\gamma_{max}$ ,  $\gamma_a$ .
- $\odot$  Неизвестные:  $\omega_2$ , Q;
- Произвольные, выбираемые системой: L, B, T.

Первую категорию параметров можно интерпретировать как заданные пользователем системы. Они фиксированы и не могут меняться для определения более хорошего порога.

Вторая категория зависит от входных параметров и определяется алгоритмом работы.

Третья категория зависит от ряда, подаваемого системе и вообще говоря не известны.

Четвертая категория параметров - те, которые система может подстраивать под тот или иной ряд. Позже попробуем оценить их влияние на оценку системы.

## Оценка системы

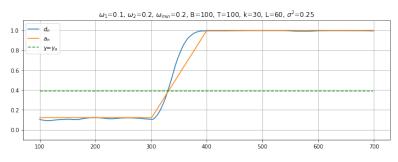
Зафиксируем дисперсию шума  $\sigma^2=0.25$  и введем характеристики системы:

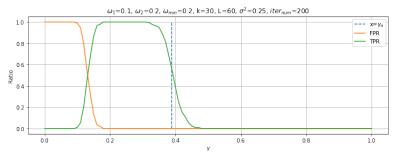
- ullet  $FP(\gamma)$  преодоление порога  $\gamma$  кривой  $d_n$  до момента Q
- ullet  $TP(\gamma)$  преодоление порога  $\gamma$  кривой  $d_n$  в промежутке [Q,Q+k]

Значения параметров рассмотренных категорий оставим такими же.

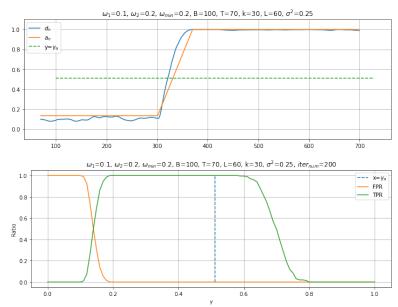
Промоделируем реализации шума  $n_{iter}=200$  раз и для  $\forall \gamma \in [0,1]$  с шагом 0.01 определим  $FPR(\gamma)=\frac{FP}{n_{iter}}$  и  $TPR(\gamma)=\frac{TP}{n_{iter}}$ . Также будем смотреть на  $FPR(\gamma_a)$ .

## Оценка системы

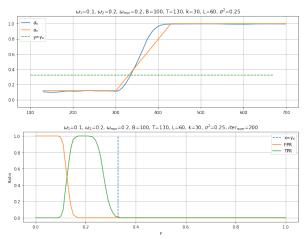




# Оценка влияния параметров: Т=70



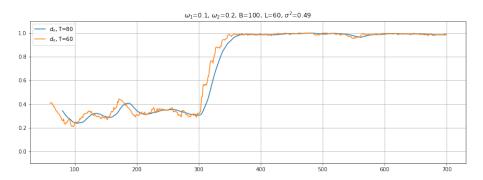
## Оценка влияния параметров: T=130



Из изображений видно, что влияя на параметр T мы можем регулировать скорость возрастания  $d_n$  на переходном интервале и добиться основного требования к  $a_T$  — значения должны быть не больше чем у  $d_n$ .

# Оценка влияния параметров: $T \approx L$

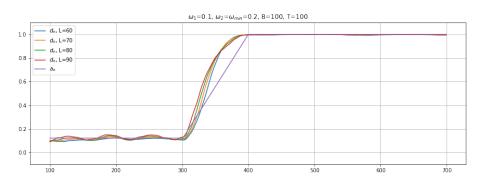
Выше было видно, что уменьшая T, мы можем уменьшить значение  $FPR(\gamma_a)$ . Однако при  $T\to L$ , количество элементов в тестовых рядах для подсчета индекса неоднородности g сокращается, усиливая влияние шума на подсчет элементов  $d_n$ , что приводит к усилению колебаний и увеличению  $FPR(\gamma_a)$ .



# Оценка влияния параметров: L

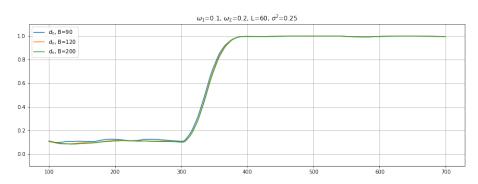
Как было отмечено ранее, сходимость  $g_a$  и g достигается при достаточно больших L, однако уменьшая L, переходный интервал  $d_n$  более линеен.

Изменяя параметр L, мы регулируем скорость возрастания кривой  $d_n$ . Таким образом, подстраивая параметр L мы можем определять  $\hat{Q}$  раньше момента Q+k.



# Оценка влияния параметров: В

В целом, параметр B не влияет на устойчивость системы в силу предположении о наличии исторических данных и отсутствия влияния на переходный интервал  $d_n$ .



## Дальнейшие планы

💶 Исследовать применимость описанной системы.

## Литература:



Golyandina, N., Nekrutkin, V., & Zhigljavsky, A. (2001). Analysis of time series structure: SSA and related techniques. Chapman & Hall/CRC.